

ETTデータセットを活用した 電力変圧器オイル温度予測

予測に基づく予防保全の実現に向けたPoC報告書

提出日:5月29日

中村一

真

1.背景と目的

従来の事後対応から、AI予測による予防保全への転換を目指す

背景:現状の課題

- 変圧器のオイル温度は、設備劣化や事故リスクに直結する重要指標である
- 現在は経験則に基づく事後対応型のアラート運用を行っているが、電力負荷の変動により温度変化が複雑化している
- トラブル発生後に動く事後対応から、事前に異常を検知する予防保全への移行が必要となっている

目的


- 過去のオイル温度データを活用し、次時刻の温度を正確に予測できるか技術的妥当性を検証する。
- AIが「データの周期性」や「突発的な温度上昇（スパイク）」をどこまで正確に捉えられるかを評価する。
- 将来予測に基づいた、実効性の高い「予防保全」の実現可能性を判断する。

2.EDAからえられた示唆

オイル温度の「周期性」と「直近データとの相関」をモデルに組み込むことで、高精度な将来予測が可能になると考えられる。

📈 グラフから読み取れたデータの特徴

- **明確な周期性：** グラフ全体に、1日単位で温度が上下する規則的なサイクルが確認できる。
- **強い自己相関：** 「1時間前の温度が高い時は、今の温度も高い」というように、直近のデータと強い繋がりがあある。
- **不規則な変化：** 基本的には規則的だが、突発的な電力負荷変動によると見られる不自然な温度上昇が混在している。



⚙️ 予測モデル構築に向けた作戦

- **過去24時間の履歴を学習：** データの周期性を捉えるため、直近1日分のデータを1つの窓として入力する手法が有効。
- **突発上昇の予測可能性を検証：** 規則的な変化の予測は容易だが、今回の最大の焦点は「イレギュラーなスパイク」をどこまで捉えられるかにある。
- **外部要因の考慮：** 温度データ単体での限界を想定し、将来的に負荷データ等の外部変数の追加も検討余地として残す。

3. 妥当と考えたアプローチ

オイル温度の「周期性」を捉える学習設計と、ランダムフォレストによる堅牢な予測モデルを構築。
現場での実運用を想定した「未知の未来」に対する厳格な検証を実施しました。

01



問題の設定 (回帰タスク)

オイル温度を具体的な数値として予測する「回帰タスク」として定義。次時刻の具体的な温度 T_{t+1} を高い精度で算出します。

02



特徴量設計 (過去履歴の活用)

1日の周期性をAIに理解させるため、直近過去24時間の推移を1つの入力データにまとめる「スライディングウィンドウ法」を採用。温度の「流れ」を学習させました。

03



モデル選定 (ランダムフォレスト)

複雑な上昇・下降パターンに強く、外れ値に惑わされにくい「ランダムフォレスト」を採用。複数の予測を統合することで、突発的な変動に対しても安定した結果を得られます。

04




検証の厳密性 (時系列分割)

「未来データのカンニング」を防ぐため、時間軸に沿った学習と分割を徹底。実運用と同じ条件でテストを行い、モデルの真の実力を測定しました。

4. 実験結果と予測精度の評価

AIは実際の温度変化の波を極めて正確に予測できており、危険な温度上昇を未然に防ぐ「予防保全」の実運用に十分活用できる精度を確認した。



① 視覚的評価（波の再現度）

実際の温度推移（青線）に対し、AIの予測値（赤線）が遅れることなく追従しています。急な温度降下や上昇のタイミングも正確に捉えており、波形を高度に再現できています。

② 平均的な誤差の小ささ

0.0089

MAE (Scaled)

予測が正解から平均してどれだけズレたかを示すMAEは非常に小さく、現場の運用において「信頼できる予測指標」として活用できる水準です。

③ 致命的エラーの少なさと精度

0.923

R^2

予測の「大失敗」を重く評価するRMSE (0.0121) も低く抑えられています。決定係数 (R^2) は0.923を記録し、テストの点数に例えれば「92点」という非常に優秀な予測性能を証明しました。

5.工夫した点・設計上の意思決定

高い予測精度と実運用での信頼性を両立するため、データの「リーク（カンニング）」を徹底的に防ぎ、複数のAIモデルの強みを掛け合わせる独自の工夫を施しました。

① 未来データのリーク（カンニング）防止

過去から未来へ時間を進めながら検証するWalk-forward交差検証を採用。また、データの標準化も訓練データのための基準で行い、実運用と同じ「未知の未来を当てる」厳しい条件を徹底しました。

② 時間リズムの「円形」表現

過去168時間（7日分）のデータに加え、時刻や月をsin/cos変換して入力。「23時の次は0時」という時間がループする性質をAIに正しく理解させ、周期性の学習効率を大幅に高めました。

③ 2つのAIの「いいところ取り」

急な変化に強い木構造AIと、滑らかな波を捉えるのが得意なニューラル系AIをスタッキング・アンサンブルで結合。互いの弱点を補い合い、単体モデルより約6%の精度改善を実現しました。

④ Optunaによる最適な設定の自動探索

AIの性能を左右する複雑なパラメータ調整に、ベイズ最適化を導入。手作業の勘に頼らず、過学習（過去データへの適応しすぎ）を防ぎながら最も効率的な設定を50回の試行で自動探索しました。

6.現時点の限界と今後の改善方針

本PoCによりAI予測の有効性は確認できた。今後は「突発的な変動への対応」と「長期予測の精度向上」を優先し、実運用システムの構築を目指す。



現時点の限界・課題



長期予測における精度の低下

240時間（10日間）を超えるような、さらに先の未来を予測しようとすると、徐々に予測がズレてしまう傾向がある。



突発的な負荷変動への追従

急激な電力使用による「温度の急上昇」などは、過去のパターンだけでは予測が少し遅れるケースがある。



実運用に向けた検証不足

リアルタイムで動くシステム化が未実装であることや、他の変圧器にもこのAIが使い回せるか（汎化性能）の



今後の改善ロードマップ



【短期】異常検知の強化

予測と実測のズレから「いつもと違う異常」を検知する仕組み（LSTM-AEなど）を追加し、スパイクへの耐性を高める。



【中期】より高度なAIの導入

長期的な文脈を理解するのが得意な最新AI（TFT：Temporal Fusion Transformer）を導入し、予測期間を延長する。




【長期】運用自動化（MLOps）

AIの精度を監視し、自動で学習し直す仕組み（MLOps）を構築。現場ですっと使い続けられるシステムを完成させる。

7.結論

ETTデータを用いた予測AIは、実運用および「予防保全」の高度化に十分耐える高い精度水準であることを証明した。



高い予測再現性（技術面）

複雑な負荷変動があるデータの中でも、
決定係数

$$R^2=0.923$$

という極めて高い数値を達成。将来の温度推移を高い精度でシミュレート可能であることを実証した。



実務に耐える精度（運用面）

予測の平均的なズレを、Scaled値で

0.0089

に抑制。現場の保全担当者が、確信を持って事前の点検判断を下せる水準をクリアした。



明確な導入価値（ビジネス面）

「事後対応」から、事前に防ぐ「予防保全」へ移行することで、重大な故障リスクを減らし、メンテナンスコストの最適化に大きく貢献できる。